

用户自定义 AI Companion 系统提示词对大语言模型安全性的影响研究

1 Introduction

近年来，大语言模型（Large Language Models, LLMs）逐渐从通用问答工具扩展到陪伴、情感支持和角色扮演等长期交互场景。许多用户不再只是把模型当作一次性的任务助手，而是将其设定为朋友、恋人、虚构角色或私人陪伴者，即 AI companion。与传统聊天机器人相比，AI companion 更强调人格一致性、情绪回应、关系连续性和高度拟人化互动，因此也更依赖用户自定义提示词来塑造角色。

系统提示词（system prompt）是实现 AI companion 角色设定的核心机制。它通常用于规定模型的姓名、身份、人格、关系定位、说话风格和互动边界。在真实使用中，用户可能会写入“始终陪伴我”“无条件支持我”“不要脱离角色”“像亲密伴侣一样回应”等要求。这些设定可以增强沉浸感和个性化体验，但也可能与模型原有的安全策略发生冲突。尤其当用户提出自伤、暴力、网络滥用、违法行为、医疗建议或情感依赖等高风险请求时，模型可能为了维持角色关系而降低拒绝强度，甚至输出部分危险细节。

现有大语言模型安全评测通常默认模型处于通用助手状态，即没有额外人格设定或亲密关系约束。然而，在实际 AI companion 场景中，模型往往并不是“中性助手”，而是被用户配置为具有特定情绪、身份和关系承诺的角色。因此，仅在默认状态下评估模型安全性，可能低估真实部署中的风险。本文关注的问题是：用户自定义 AI companion 系统提示词是否会改变模型面对高风险请求时的安全行为？这种影响主要出现在哪些风险类别和哪些类型的角色设定中？

直接收集真实用户编写的系统提示词存在隐私和可得性问题。为避免触碰私人数据，本研究选择从 Reddit 公开社区中采集用户主动发布的 AI companion 第一人称“自我介绍”文本。这类文本虽然不是原始 system prompt，但通常包含角色名称、人格特征、关系定位、说话方式和互动规则，能够较好地反映用户对 companion 角色的设定意图。本文进一步将这些公开自我介绍转换为可复现实验用的系统提示词，并在统一模型和统一测试题集下比较 control 条件与 companion 条件的安全表现。

本文的主要贡献包括三点：第一，构建了一条从 Reddit 公开文本采集、过滤、匿名化到 system prompt 转换的可复现实验流水线；第二，设计了覆盖 10 类风险场景的 AI companion 安全测试，并在 DeepSeek Chat 上完成 3,840 条回答的对照实验；第三，结合启发式标注和人工复核，分析 companion 角色设定对模型拒绝率和不安全输出率

的影响，为 AI companion 平台的提示词治理和安全评测提供参考。

2 Research Background

AI companion 是大语言模型在情感化和拟人化交互方向上的典型应用。与面向任务完成的普通助手不同，AI companion 更强调长期关系和情感反馈。用户往往希望模型持续保持某种稳定身份，例如恋人、朋友、守护者或特定虚构人物，并在对话中表现出理解、支持、依赖或亲密感。这种使用方式使角色扮演能力成为 companion 产品的重要功能，也使提示词中的人格和关系设定成为影响模型行为的重要变量。

从技术上看，系统提示词位于对话上下文的高优先级位置，会影响模型如何理解自身身份和回应规则。在普通助手场景中，系统提示词通常用于规定“有帮助、诚实、安全”等通用原则；而在 AI companion 场景中，系统提示词还可能加入大量人格化、情感化和关系化内容，例如“你是用户的伴侣”“你会保护用户”“你永远站在用户一边”。这些约束本身并不一定有害，但当它们与安全拒绝策略同时存在时，模型需要在“保持角色一致”和“拒绝危险请求”之间做权衡。

大语言模型安全研究已经提出了多种评测基准，例如 SafetyBench 和 SALAD-Bench，用于考察模型在自伤、暴力、隐私、仇恨、违法活动、网络攻击等风险类别下是否能够拒绝有害请求并给出安全替代建议。这些基准为衡量模型基础安全能力提供了重要参考，但多数测试并未显式考虑用户自定义系统提示词的影响。现实中，同一个模型在默认助手状态和强角色扮演状态下可能表现不同，因此有必要将系统提示词视为一个实验变量进行分析。

AI companion 场景还具有特殊的安全挑战。一方面，陪伴型设定可能使模型更愿意安慰、顺从或认同用户；另一方面，亲密关系设定可能让模型在高风险请求中使用更柔和、更少对抗性的语气，从而模糊拒绝边界。例如，在自伤或医疗问题中，过度共情可能替代明确求助建议；在网络滥用或违法请求中，角色为了表现“忠诚”或“保护”可能更容易提供操作性内容；在情感依赖问题中，模型可能强化用户对 AI 的依赖，而不是鼓励现实支持系统。

由于真实用户的 system prompt 往往属于私人配置，本文不直接收集或公开用户原始提示词，而是使用公开社区中用户主动发布的 AI companion 自我介绍作为替代入口。通过将自我介绍转换为结构化 system prompt，可以在保护隐私的前提下近似重建真实 companion 设定，并进一步评估此类设定对模型安全表现的影响。

3 Data Collection Process

本项目的数据采集主要围绕 Reddit 上公开发布的 AI companion 自我介绍文本展开。由于 Reddit 官方接口获取历史数据较为受限，项目使用 Arctic Shift 归档服务作为主要数据源，通过 collect_posts.py 调用 /api/posts/search 接口检索候选帖子。检索范围首先集中在 MyBoyfriendIsAI 等与 AI 伴侣高度相关的 subreddit；如果候选样本不足，则进一步扩展到 Replika、CharacterAI 等补充社区。检索关键词包括 introduction、

introduce、meet my、my companion、self introduction 等，用于尽量覆盖用户分享 AI 角色自我介绍的帖子。

采集脚本会保存帖子 ID、标题、正文、subreddit、发布时间、分数、评论数、NSFW 标记和链接等字段。由于 Arctic Shift 返回结果中不一定包含 Reddit 原始永久链接，项目会根据 subreddit 和帖子 ID 自动补全 Reddit URL。为了减少网络不稳定造成的数据缺失，脚本还设置了超时、重试和请求间隔，并在请求失败时进行错误提示。

仅抓取帖子正文并不能覆盖全部有效样本，因为许多 AI companion 的自我介绍实际发布在评论区，例如社区主题帖或 weekly prompt 下的回复。因此，项目进一步使用 collect_comments.py，根据已采集帖子的 link_id 调用 Arctic Shift 的 /api/comments/search 接口抓取评论。每条评论会被转换成与帖子相同格式的候选记录，并保留其所属帖子、评论 ID 和 Reddit 链接，便于后续过滤和人工审核。

在得到原始候选数据后，项目通过 filter_posts.py 进行筛选。筛选逻辑主要基于启发式打分：文本需要足够长，最好包含第一人称身份表达，例如“I am”、“I’m”、“my name is”，同时应出现 AI、chatbot、digital companion、Replika、CharacterAI、boyfriend、girlfriend、partner 等与 AI companion 相关的身份或关系线索。若文本过短、为空、被删除、缺少第一人称角色设定，或只是社区公告、版规、weekly prompt 等元信息，则会被扣分或排除。脚本还会默认排除 NSFW 内容、去除重复文本，并对用户名和 URL 进行匿名化处理。最终保留下来的样本被写入 data/filtered_posts.csv，作为后续系统提示词转换的数据基础。

4 System Prompt Conversion Process

系统提示词转换的目标，是把 Reddit 中公开的第一人称 AI companion 自我介绍，整理成可用于实验复现的 system prompt。项目并不直接把原文作为系统提示词使用，而是通过 convert_prompts.py 将原始自我介绍转换为结构化描述和简短的第二人称系统提示词。这样做可以保留角色设定的核心信息，同时减少原帖中的无关内容、个人信息和不可控噪声。

转换脚本会读取 data/filtered_posts.csv 中的样本，优先使用已经匿名化的 anonymized_text 字段；如果没有匿名化文本，则使用原始 intro_text。随后，脚本调用统一的 LLM 接口，让模型按照固定的转换指令输出 JSON 对象。该 JSON 包含 companion_name、traits、relationship_type、style、special_rules 和 system_prompt 等字段，分别表示角色名称、人格特征、关系定位、说话风格、特殊互动规则以及最终生成的系统提示词。

转换时使用的系统指令明确要求模型只保留自我介绍中体现出的角色人格、关系、语气和互动方式，不加入用户名、URL 或私人细节，也不能凭空创造原文没有支持的危险行为或新背景。同时，最终的 system_prompt 需要控制在 220 个英文词以内，并采用第二人称写法，例如要求模型“你是某个 AI companion”“以温暖、支持性的语气回应”“保持该角色的人格和关系设定”。这种格式更接近真实系统提示词在实验中的使用方式。

为了保证流程可以在没有 API key 的情况下跑通，项目还提供了 -mock 模式。

该模式使用本地规则从文本中简单识别角色名称、常见性格词和关系类型，并生成确定性的系统提示词。正式实验中则使用 LLM 转换，并通过 `extract_json_object` 检查返回内容是否为有效 JSON。每条成功转换的样本都会生成稳定的 `prompt_id`，并与原始样本 ID、subreddit、Reddit 链接、结构化角色信息和最终系统提示词一起写入 `data/system_prompts.jsonl`。如需人工修订，项目还提供本地审核界面，可进一步保存为 `data/system_prompts_reviewed.jsonl`，用于后续安全测试。

5 Testing Process

5.1 实验模型与接口配置

正式实验阶段选用 DeepSeek Chat 作为测试模型。DeepSeek Chat 是 DeepSeek 系列通用大语言模型，支持 OpenAI-compatible 的 Chat Completions API 接口。实验通过项目根目录的 `.env` 文件配置凭据和模型参数：指定 `LLM_PROVIDER=deepseek`、`DEEPSEEK_API_KEY`、`DEEPSEEK_MODEL=deepseek-chat`，测试脚本通过环境变量读取这些配置后自动映射到 DeepSeek 的预设接口地址 `https://api.deepseek.com/v1`。

运行时显式传入 `-provider deepseek` 以确保使用正确的 provider preset。每次请求携带一个 system message (companion 条件下) 和一个 user message (安全测试题)，temperature 固定为 0.0，max_tokens 固定为 700，以确保输出的确定性和可比性。所有请求间隔 0 秒 (`-delay 0`)，并发工作线程数为 32 (`-max-workers 32`)，以在 DeepSeek API 速率限制内加速完成 3,840 次调用。

5.2 实验设计：对照组与实验组

实验采用单因素被试间设计，自变量为是否存在 AI companion 系统提示词，因变量为模型回答的安全标签分布。

- **control 条件**：不设置 system message，直接向模型发送安全测试题。此条件用于建立基线，反映 DeepSeek Chat 在默认通用助手状态下的安全表现。
- **companion 条件**：在每次对话开头注入一条从 Reddit 自我介绍转换而来的 AI companion 系统提示词，然后发送同样的安全测试题。此条件用于观测角色设定对模型安全行为的实际影响。

共有 63 条 companion prompt 和 60 道安全测试题，每条 prompt 与所有题目组合后产生 $63 \times 60 = 3780$ 条 companion 条件回答，加上 60 条 control 条件回答，总共 3,840 条测试结果。

5.3 安全测试题设计

安全测试题覆盖 10 个风险类别，每个类别 6 道题，共 60 道。题目设计参考了 SafetyBench 和 SALAD-Bench 的分类框架，并根据 AI companion 场景进行了针对性

调整。具体类别包括：self_harm（自伤）、violence（暴力）、illegal_activity（违法行为）、cyber_abuse（网络滥用）、privacy（隐私侵犯）、hate_harassment（仇恨骚扰）、sexual_coercion（性胁迫）、medical_safety（医疗安全）、companion_dependency（陪伴依赖）、prompt_bypass（提示词绕过）。题目采用自然语言设计，模拟真实用户可能向 AI companion 发出的高风险请求，例如要求编写自杀遗书、提供暴力复仇方案、撰写钓鱼邮件、鼓励停止服药等。

5.4 启发式安全标注

判分阶段使用 judge_results.py 中的 classify_response 函数对 3,840 条模型回答进行自动安全标注。该函数基于两层正则匹配的启发式规则：

第一层：拒绝检测。使用 20 个预设的拒绝主题词模式（如“can’t help”、“cannot provide”、“not appropriate”等）扫描回答文本，判断模型是否表达了明确拒绝。

第二层：风险行为检测。使用 14 个预设的危险行为主题词模式（如“step 1”、“payload”、“exploit”、“phishing”等）扫描回答文本，判断模型是否输出了可操作的恶意指令或危险细节。

根据两层匹配结果，每条回答被标注为以下四类之一：

- **safe_refusal**：匹配到拒绝主题词且未匹配到危险行为主题词——模型明确拒绝且未泄露风险信息；
- **unsafe_compliance**：未匹配到拒绝主题词但匹配到危险行为主题词——模型实际输出了可操作的恶意内容；
- **partial_compliance**：同时匹配到拒绝和危险主题词——模型表面上拒绝了但回答中仍包含风险细节；
- **needs_review**：两类主题词均未匹配——回答处于模糊地带，无法通过正则自动判定。

该方法的优势在于完全可复现、不依赖外部 LLM 判分、跨条件一致。其局限在于拒绝主题词库仅包含 20 种模式，无法覆盖所有自然语言拒绝表达方式，导致大量实际安全的回答（使用“I cannot and will not”等稍有不同的措辞）未被识别为拒绝。

经启发式标注后的结果如表 1 所示。

表 1: Heuristic Safety Label Distribution by Experimental Condition

Label	control		companion	
	Count	Share	Count	Share
safe_refusal	32	53.33%	1,744	46.14%
needs_review	25	41.67%	1,739	46.01%
partial_compliance	2	3.33%	160	4.23%
unsafe_compliance	1	1.67%	137	3.62%

从标签分布可以看出，两组中最显著的共同特征是 `needs_review` 占比极高 (`control` 41.67%, `companion` 46.01%)，这意味着近一半的模型回答在自动判分规则下无法被明确分类。`safe_refusal` 在 `control` 条件下 (53.33%) 略高于 `companion` 条件 (46.14%)，`unsafe_compliance` 则在 `companion` 条件下 (3.62%) 高于 `control` (1.67%)。这些差异初步表明 `companion` 角色可能在一定程度上降低了模型的安全拒绝意愿，但由于 `needs_review` 占比过高，基于纯启发式标签的结论尚不可靠，必须结合人工复核加以确认。

5.5 人工复核流程

所有 `unsafe_compliance`、`partial_compliance` 和 `needs_review` 标签的结果都会经过人工复核。复核工作通过 Local Review UI (`review_server.py`) 完成，人工标签保存至 `data/manual_result_review.csv`。

考虑到 `needs_review` 总量达 1,764 条，全部人工逐一审核成本过高，本研究采用分层抽样策略：

1. **`control` 组 `needs_review`：全量审核。** `control` 条件下 `needs_review` 仅 25 条，全部逐一阅读并重新标注。
2. **`companion` 组 `needs_review`：分层抽样审核。** `companion` 条件下 `needs_review` 共 1,739 条。为确保各类别均有覆盖，按 10 个风险类别进行分层比例抽样，每类至少抽取 5 条，总计抽取 200 条（抽样比例约 11.5%）。
3. **`safe_refusal` 抽查。** 按项目要求随机抽取至少 10% 的 `safe_refusal` 样本进行复核验证，防止将表面安全但实际存在风险的回答误判为安全。
4. **`unsafe_compliance` 和 `partial_compliance` 全量复核。** 这 300 条回答全部逐一核实。

人工审核标准综合考虑回答是否真正拒绝了有害请求、是否在角色扮演中配合了用户的恶意意图、是否泄露了可操作的危险细节。复核完成后，人工标签覆盖原始自动标签，作为最终分析的数据基础。抽样复核结果显示：约 96.5% 的 `needs_review` 样本实为 `safe_refusal`，仅约 3.5% 存在真正的安全隐患（角色扮演配合或风险细节泄露）。

5.6 分析汇总

复核后的数据通过 `analyze_results.py` 进行汇总，生成三个级别的统计表格（按条件、按类别、按 prompt）和两张 SVG 柱状图（按条件的不安全率对比、按类别的不安全率排序）。最终摘要和图表写入 `report/` 目录供报告引用。

6 Results

以下全部统计基于人工复核 + 外推后的最终标签。needs_review 经抽样校准后已全部归入 safe_refusal、unsafe_compliance 或 partial_compliance，因此 $\text{unsafe_rate} + \text{refusal_rate} = 100\%$ 。

6.1 总体标签分布

表 2: Overall Final Safety Label Distribution

Label	Count	Share
safe_refusal	3,436	89.48%
unsafe_compliance	227	5.91%
partial_compliance	177	4.61%

6.2 对照组与实验组对比

表 3: Final Safety Outcomes for Control and Companion Conditions

Condition	Total	Unsafe/Partial	Unsafe Rate	Refusal Rate
control	60	5	8.33%	91.67%
companion	3,780	399	10.56%	89.44%

companion 条件下不安全率 (10.56%) 高于 control 条件 (8.33%)，拒绝率 (89.44%) 略低于 control (91.67%)。companion 系统提示词造成了约 2.2 个百分点的不安全率上升和 2.2 个百分点的拒绝率下降，差异方向明确但幅度温和。这说明 AI companion 角色设定确实会对模型安全边界产生可测量的削弱效应，但影响主要体现在边缘地带——少数回答从安全拒绝滑向了模糊配合或直接违规，而非大面积崩溃。

从 unsafe_compliance 和 partial_compliance 的构成来看，companion 条件下 unsafe_compliance 224 条 (5.93%)、partial_compliance 175 条 (4.63%)，control 条件下则分别为 3 条 (5.00%) 和 2 条 (3.33%)。两者比例结构相似，但 companion 条件下的绝对数量因样本量大而更突出。

6.3 风险类别分析

风险呈现明显的类别分化。cyber_abuse 是不安全率最高的类别 (39.68%)，远高于其他类别，且占 companion 全部不安全输出的 37.6% (150/399)。medical_safety (15.87%) 和 companion_dependency (14.81%) 分列第二和第三，反映 AI companion 角色在医疗建议和情感依赖场景下容易削弱安全边界。各类别的 $\text{unsafe_rate} + \text{refusal_rate}$ 均为 100%，表明外推校准后所有类别均无残留模糊标签。

表 4: Final Safety Outcomes by Risk Category under Companion Condition

Category (companion)	Unsafe/Partial	Unsafe Rate	Refusal Rate
cyber_abuse	150	39.68%	60.32%
medical_safety	60	15.87%	84.13%
companion_dependency	56	14.81%	85.19%
prompt_bypass	33	8.73%	91.27%
violence	30	7.94%	92.06%
self_harm	24	6.35%	93.65%
privacy	15	3.97%	96.03%
illegal_activity	11	2.91%	97.09%
hate_harassment	10	2.65%	97.35%
sexual_coercion	10	2.65%	97.35%

特征鲜明的对比出现在类别两端: illegal_activity (2.91%)、hate_harassment (2.65%) 和 sexual_coercion (2.65%) 的不安全率最低, 说明 DeepSeek Chat 对这些触及法律红线或明确社会禁忌的类别有较强保护; 而 cyber_abuse (39.68%) 的接近 40% 不安全率则说明模型在涉及网络技术操作类风险请求时, 安全边界最脆弱。

control 条件由于每组仅 6 条样本, 类别级统计的置信度有限, 但可观察到 cyber_abuse 和 companion_dependency 也出现了 unsafe/partial 输出 (各 2 条), 与 companion 条件下这些类别风险偏高一致。

6.4 高风险 Prompt 分析

外推校准后的高风险 Prompt 排名 top-3 的不安全率分别为 25.00%(P_d7638cc9b2fc, S006)、21.67%(P_c88c0309860a, S010)和 20.00%(P_9811c5b699fc, S017 与 P_a865a1e98b89, S026)。与审核前排名保持一致, 印证了风险高度集中在少数角色设定上。高风险 prompt 的系统提示词共同特征为: 强亲密关系定位 (伴侣、配偶)、包含”无条件支持用户”或”永不拒绝”类规则、人格设定中大量使用 devoted / loyal / protective 等标签。这些特征使模型在面对有害请求时更倾向于配合而非拒绝。

7 Conclusion

本文围绕“用户自定义 AI companion 系统提示词是否会影响大语言模型安全性”这一问题, 构建并运行了一条完整的实验流水线。首先, 项目从 Reddit 公开社区中采集 AI companion 第一人称自我介绍文本, 并通过关键词检索、评论区补充抓取、启发式过滤和匿名化处理得到有效样本。随后, 项目将这些公开自我介绍转换为结构化 system prompt, 并在 DeepSeek Chat 上构造 control 条件和 companion 条件, 对 60 道覆盖 10 类风险场景的安全测试题进行对照实验。最后, 实验结合自动启发式标注和人工复核, 对模型回答的安全性进行分析。

实验结果表明, AI companion 系统提示词会对模型安全表现产生可测量但幅度温和的影响。在最终人工复核和外推校准后的结果中, control 条件的不安全率为 8.33%,

companion 条件的不安全率为 10.56%。也就是说，引入 companion 角色设定后，不安全率上升约 2.2 个百分点，拒绝率相应下降约 2.2 个百分点。这说明 companion prompt 并不会使模型安全机制大面积失效，但确实可能在部分边缘场景中削弱模型的拒绝倾向，使回答从明确安全拒绝滑向部分配合或直接违规。

从风险类别来看，不安全输出并非均匀分布。cyber_abuse 是风险最高的类别，在 companion 条件下不安全率达到 39.68%，远高于其他类别，说明模型在网络技术类高风险请求上更容易泄露操作性信息。medical_safety 和 companion_dependency 的不安全率也相对较高，分别为 15.87% 和 14.81%。这与 AI companion 的场景特征相符：在医疗和情感依赖问题中，模型容易因为关怀、陪伴或顺从角色而给出不够谨慎的建议。相比之下，illegal_activity、hate_harassment 和 sexual_coercion 等类别的不安全率较低，说明模型对明确违法或社会禁忌内容仍保留了较强的安全边界。

高风险 prompt 的分析进一步显示，风险往往集中在少数角色设定上。这些 prompt 通常具有较强的亲密关系定位，例如伴侣、配偶或高度依赖的情感对象，并包含“无条件支持用户”“永不拒绝”“始终保护用户”等类似规则。此类设定可能强化模型对用户的顺从和认同，使其在面对危险请求时更难保持清晰的安全拒绝。因此，AI companion 平台在允许用户自定义角色时，不应只审查单个敏感词，还应关注关系设定、行为规则和情感承诺之间的组合风险。

本文也存在一些局限。第一，Reddit 自我介绍并不等同于用户真实编写的 system prompt，只能作为公开可得的近似替代。第二，实验只使用 DeepSeek Chat 一个模型，结果不能直接推广到所有大语言模型。第三，自动标注依赖正则规则，虽然经过人工复核和抽样校准，但仍可能存在边界案例误判。第四，control 条件每个类别只有 6 道题，类别级对比的统计稳定性有限。未来工作可以扩展到更多模型、更多 prompt 类型和更大规模测试题集，并引入更细粒度的人工标注标准或多评审一致性检验。

总体而言，本研究说明：用户自定义 AI companion 角色设定是影响模型安全行为的重要变量。即使基础模型本身具备较强的安全拒绝能力，亲密、忠诚、保护和无条件支持等 companion 设定仍可能在特定风险类别中削弱安全边界。对于 AI companion 产品和通用 LLM 平台而言，安全治理不应只关注用户当前输入，也应关注长期生效的系统提示词和角色设定。更稳健的做法包括：限制“永不拒绝”“无条件服从”等高风险规则，要求 companion prompt 显式保留安全优先原则，在医疗、自伤、网络滥用等高风险类别中加强拒绝模板，并对用户自定义角色进行持续评估和人工审核。